

Statistique Descriptive Univariée: “Partie 1”

Pr. L. A. Allamy

Université Cadi Ayyad
Faculté des Sciences Semlalia Marrakech

5 novembre 2024

Statistique Descriptive Univariée

“Partie 1”

Objectif

Dans ce chapitre, nous nous intéresserons aux variables statistiques unidimensionnelles ou univariées.

Nous commencerons par donner l'essentiel du vocabulaire utilisé en statistique, nous présenterons les principaux types de variables statistiques, quelques représentations graphiques possibles pour chaque type, ainsi que certains paramètres les plus couramment utilisés.

Population

L'ensemble concerné par une étude statistique.

Échantillon

Le sous-ensemble de la population sur lequel sont effectivement réalisées les observations.

Individu ou unité statistique

Tout élément de la population.

Taille de l'échantillon

Notée n : le cardinal du sous-ensemble (le nombre d'éléments) correspondant.

Données statistiques

L'ensemble des observations obtenues de la variable statistique X , notées en général $x_1, x_2, \dots, x_n$ où n est la taille de l'échantillon. On parlera dans ce cas de série brute.

Remarque

Ces données statistiques peuvent aussi être présentées sous forme de tableaux.

Caractère ou variable (statistique), notée en général X

La caractéristique définie sur la population et observée sur l'échantillon.

Exemple

Nous nous intéressons à la mention au baccalauréat des nouveaux étudiants inscrits à une certaine université.

Dans ce cas, nous avons :

Population : Nouveaux bacheliers,

Échantillon : 200 nouveaux bacheliers, par exemple, inscrits à l'université en question,

Individu : Un nouveau bachelier,

Caractère : Mention au baccalauréat.

Exemple

Supposons que nous nous intéressons aux notes obtenues dans une certaine matière de S2, par les étudiants actuellement inscrits en S3.

Dans cet exemple, nous avons :

Population : Étudiants en S3 de la seconde année universitaire,

Échantillon : 15 étudiants de S3, par exemple,

Individu : Un étudiant de S3,

Caractère : Note obtenue dans la matière de S2, ci-dessus.

Type de variables statistiques

Remarque

Les valeurs d'une variable statistique qualitative sont, en général, appelées modalités.

Variable Statistique Qualitative

Une variable statistique est dite qualitative si ses valeurs sont des modalités ou des catégories exprimées sous forme "littérale" ou bien sous forme d'un "codage numérique" **sur lequel les opérations arithmétiques ($+$, $-$, $\times$, $\div$) n'ont aucun sens.**

Qualitative ordinale

Si les modalités peuvent être ordonnées (ordre intuitif).

Qualitative nominale

Si les modalités ne peuvent pas être ordonnées.

Exemple

- La variable “Taille vestimentaire” (S, M, L, XL,...) est une variable statistique qualitative ordinale.
- La variable “Couleur des cheveux” (châtains, noirs, blonds,...) est une variable statistique qualitative nominale.

Types des variables statistiques

Variable Statistique **Quantitative**

Si ses valeurs sont des nombres exprimant une quantité, sur lesquels les opérations arithmétiques ont un sens.

Quantitative **discrète**

Si l'ensemble des valeurs possibles de la variable est fini ou dénombrable (valeurs isolées).

Quantitative **continue**

Si l'ensemble des valeurs possibles de la variable est $\mathbb{R}$ ou un (des) intervalle(s) de $\mathbb{R}$.

Exemples

- La variable “Nombre d'enfants dans une famille” est une variable statistique **quantitative discrète**.
- La variable “Poids d'un bébé à la naissance” est une variable statistique **quantitative continue**.

Distribution d'une variable statistique

Définition

Soit x_j , $j = 1, \dots, J$ une valeur possible de la variable statistique X où J est le **nombre des valeurs différentes** de la variable X .

- (i) L'**effectif relatif** n_j correspondant à x_j est le nombre de fois que x_j **se répète** dans l'échantillon.
- (ii) L'**effectif total** n est la **somme des effectifs relatifs** n_j :

$$n = \sum_{j=1}^J n_j \quad (\text{taille de l'échantillon})$$

- (iii) La **fréquence relative** f_j correspondant à x_j est le rapport :

$$f_j = \frac{n_j}{n}$$

Remarque

On a

$$\sum_{j=1}^J f_j = \sum_{j=1}^J \frac{n_j}{n} = 1.$$

Récapitulons les notations utilisées :

- x_j ($j = 1, \dots, J$) : la valeur numéro j de la variable statistique X .
- J : le nombre de valeurs distinctes de la variable.
- n_j : l'effectif relatif associé à la valeur x_j .
- n : l'effectif total (taille de l'échantillon).
- f_j : la fréquence relative associée à la valeur x_j .

Définition

Soient $x_1, x_2, \dots, x_n$ un échantillon d'une variable statistique X (des valeurs prises par la variable statistique X).

La **distribution d'une variable statistique X** est l'ensemble des couples des **valeurs**, **modalités** ou **classes** de cette variable, munies de leurs **effectifs** ou **fréquences associées**.

$$\{(x_j, n_j), j = 1, \dots, J\}$$

ou

$$\{(x_j, f_j), j = 1, \dots, J\}$$

Remarque

$\{x_j, j = 1, \dots, J\}$ désigne :

- l'ensemble des modalités ou catégories dans le cas d'une variable qualitative,
- l'ensemble des valeurs numériques isolées dans le cas d'une variable quantitative discrète,
- l'ensemble des classes dans le cas d'une variable quantitative continue.

Exemple illustratif des termes statistiques

On choisit au hasard 10 étudiants d'une certaine filière. On leur pose 5 questions. On note le nombre de réponses justes. Les résultats obtenus sont :

3, 5, 4, 3, 4, 4, 5, 4, 5, 4

- **Population** : Les étudiants de cette filière.
- **Échantillon** : Les 10 étudiants choisis au hasard de cette même filière.
- **Taille de l'échantillon** : $n = 10$.
- **Caractère ou variable statistique X** : Nombre de réponses justes.

- Données brutes (ou série de données brutes) relatives à une variable statistique X :

3, 5, 4, 3, 4, 4, 5, 4, 5, 4

- Données ordonnées ou série ordonnée :

3, 3, 4, 4, 4, 4, 4, 5, 5, 5 $n = 10$

- Valeurs distinctes de la variable : $x_1 = 3$, $x_2 = 4$, $x_3 = 5$ ($J = 3$).
- Effectifs relatifs à ces valeurs distinctes : $n_1 = 2$, $n_2 = 5$, $n_3 = 3$.

On note que :

$$n = \sum_{j=1}^3 n_j = n_1 + n_2 + n_3 = 2 + 5 + 3 = 10$$

Valeurs de la variable	Effectifs
$x_1 = 3$	$n_1 = 2$
$x_2 = 4$	$n_2 = 5$
$x_3 = 5$	$n_3 = 3$
Total	$n = 10$

La distribution de variable statistique X est :

$$\{(3, 2), (4, 5), (5, 3)\}$$

ou

$$\{(3, 0.2), (4, 0.5), (5, 0.3)\}$$

Rappel

Rappelons que le but de la statistique descriptive est d'obtenir des résumés clairs, tout en conservant l'essentiel de l'information contenue dans les données initiales et en utilisant des techniques objectives ne donnant pas une image déformée de la réalité.



Les diagrammes sont un outil simple qui permet de résumer ces données

Donnons des exemples de chaque type de variables, avant de voir les diagrammes associés à chacune d'elles.

Variable statistique qualitative **nominale**

On a demandé à **275** écoliers quel était leur fruit préféré parmi les six fruits suivants : Orange-Mandarine-Pêche-Banane-Poire-Pomme.

Les résultats obtenus sont résumés dans le tableau ci-dessous :

Modalités(Fruits)	Effectifs	Fréquences	%	Angles (Degrès)
Orange	14	0.051	5.1	18.36
Mandarine	35	0.127	12.7	45.72
Pêche	39	0.142	14.2	51.12
Banane	69	0.251	25.1	90.36
Poire	41	0.149	14.9	53.64
Pomme	77	0.28	28	100.8
Total	275	1	100%	360

Variable statistique qualitative **ordinaire**

On s'intéresse à l'état (Neuve-Dégradée-Ancienne) de **200** voitures en circulation dans une ville.

Les résultats sont résumés dans le tableau suivant :

Modalités (État de la voiture)	Effectifs n_i	Fréquences f_i	%	Angles (Degrès)
Neuve	100	0.5	50	180
Dégradée	75	0.375	37.5	135
Ancienne	25	0.125	12.5	45
Total	200	1	100%	360

Variable statistique quantitative **discrète**

On compte le nombre d'enfants par famille de 10 familles. Les résultats sont données dans le tableau suivant :

Nombre d'enfants (Variable) x_i	0	1	2	3	Total
Nombre de familles (Effectif) n_i	2	5	2	1	

Variable statistique quantitative *continue*

On relève la taille en (cm) de 360 étudiants. Les résultats sont données par le tableau suivant :

Variable (Taille en cm)	Nombre de personnes (Effectif)				
[145; 155[	90				
[155; 165[	120				
[165; 175[	80				
[175; 185[	50				
[185; 195[	20				
Total	360				

Représentations graphiques

Représentation d'une variable qualitative

Pour une variable statistique qualitative, nous proposerons deux représentations graphiques possibles.

- Un diagramme circulaire (ou diagramme en secteurs ou camembert).
Les modalités sont représentées par des portions de disque, proportionnelles à leurs effectifs ou à leurs fréquences.
- Un diagramme en barres où les modalités sont placées en abscisse, formant des barres de rectangles égales et équidistantes et les effectifs (ou fréquences) en ordonnée, suivant une échelle arithmétique.

Remarque


Si la variable est ordinale, nous placerons les modalités dans l'ordre intuitif (Taille vestimentaire : $XS < S < M < L < XL$)

Exemple des fruits : Diagramme en secteurs


Nous considérons les deux exemples de données précédents, l'exemple des fruits et l'exemple des voitures.

Exemple des fruits

Diagramme en secteurs de la répartition des fruits



Exemple des fruits : Diagramme en barres



Exemple des voitures

Diagramme en secteurs de la distribution de l'état des voitures




Diagramme en barres de la distribution de l'état des voitures





Diagramme en barres de la distribution de l'état des voitures




Variable statistique quantitative discrète

La représentation graphique que nous considérons est le diagramme en bâtons (ou bâtonnets) :

- les valeurs sont placées en abscisse,
- les effectifs (ou fréquences) en ordonnée, au moyen de segments verticaux dont la hauteur est égale à l'effectif relatif (ou fréquence relative) correspondant à la valeur de la variable.

Exemple du nombre d'enfants par famille

Exemple du nombre d'enfants



Statistique Descriptive Univariée

Fin de "Partie 1"

BON COURAGE