

Statistique Descriptive Univariée "Partie 2"

Pr. L. A. Allamy

Université Cadi Ayyad
Faculté des Sciences Semlalia Marrakech

5 novembre 2024

Statistique Descriptive Univariée

“Partie 2”

Variable Statistique quantitative

Dans le cas continu, nous commençons par diviser ou découper l'intervalle des valeurs de la variable en un certain nombre de classes $\{[e_i; e_{i+1}[; i = 1, \dots, K\}$ et nous déterminons les effectifs associés à chaque classe (ainsi que les fréquences et les pourcentages).

Le graphique correspondant est un "histogramme".

L'histogramme est un graphique qui permet de représenter une **distribution continue regroupée en classes**.

Il se présente sous forme de rectangles juxtaposés ou contigus, dont les surfaces (et **non pas les hauteurs**) sont :

- proportionnelles aux effectifs (on parlera d'histogramme des effectifs)
- proportionnelles aux fréquences (on parlera d'histogramme des fréquences)

Variable Statistique quantitative

Remarques

- Si les classes sont de **même amplitude** (largeur de la classe) ($a_1 = a_2 = \dots = a_K$), nous plaçons, en ordonnée les effectifs ($n_i; i = 1, \dots, K$) ou les fréquences ($f_i; i = 1, \dots, K$).
- Sinon, c'est à dire si les **amplitudes sont différentes**, nous plaçons, en ordonnée $\frac{n_i}{a_i}$ ou $\frac{f_i}{a_i}$.

Variable Statistique quantitative


On considère la série statistique ordonnée, de valeurs brutes, relative aux âges des 50 membres d'un club sportif :

17	18	19	20	22	22	23	23	24	25
25	26	26	27	27	27	27	27	28	28
28	28	28	29	29	29	29	30	30	30
30	30	31	31	31	31	31	32	32	33
33	34	35	35	36	36	38	39	40	41

Dans un premier temps, nous regroupons ces données en cinq classes de même amplitude, dont la borne inférieure de la 1^{ère} classe est 15 et la borne supérieure de la dernière classe est 45. Nous obtenons les résultats suivants :

Classes d'âge	a_i	C_i	n_i	f_i	Haut. $h_i = \frac{n_i}{a_i}$	Haut. $d_i = \frac{f_i}{a_i}$
[15; 21[	6	18	4	0.08	4/6	0.08/6
[21; 27[	6	24	9	0.18	9/6	0.18/6
[27; 33[	6	30	26	0.52	26/6	0.52/6
[33; 39[	6	36	8	0.16	8/6	0.16/6
[39; 45[	6	42	3	0.06	3/6	0.06/6
Total			50	1		


Histogramme des âges avec amplitudes égales



Dans un second temps, nous regroupons ces données en six classes d'**amplitudes différentes**, [15; 18[, [18; 21[, [21; 25[, [25; 30[, [30; 35[et [35; 45[.

Nous obtenons les résultats suivants :

Classes d'âge	a'_i	C'_i	n'_i	f'_i	Haut. $h'_i = \frac{n'_i}{a'_i}$	Haut. $d'_i = \frac{f'_i}{a'_i}$
[15; 18[	3	16.5	1	0.02		
[18; 21[	3	19.5	3	0.06		
[21; 25[	4	23	5	0.1		
[25; 30[	5	27.5	18	0.36		
[30; 35[	5	32.5	15	0.3		
[35; 45[	10	40	8	0.16		
Total			50	1		



Histogramme avec amplitudes différentes

Paramètres statistiques

Paramètres de position ou caractéristique de valeur centrale ou tendance centrale

La moyenne arithmétique :

Définition

On appelle "moyenne arithmétique", notée $\bar{x}$, de la série statistique $x_1, x_2, \dots, x_n$, où n est la taille de l'échantillon, la quantité :

$$\bar{x} = \frac{1}{n}(x_1 + x_2 + \dots + x_n) = \frac{1}{n} \sum_{i=1}^n x_i.$$

Calcul de la moyenne arithmétique

- (a) Sur la série **brute**, le calcul de la moyenne se fait selon la définition ci-dessus.
- (b) Si la série est présentée sous forme d'une série à **valeurs isolées** (x_j, n_j) ; $j = 1, \dots, J$ (J étant le nombre de valeurs différentes de la série), alors :

$$\bar{x} = \frac{1}{n} \sum_{j=1}^J n_j x_j = \sum_{j=1}^J f_j x_j$$

C'est une moyenne pondérée $\left(x_j, f_j = \frac{n_j}{n}\right)_{j=1, \dots, J}$

Calcul de la moyenne arithmétique

- (c) Si la série est présentée sous forme d'une série à **valeurs classées** $[e_i, e_{i+1}[; n_i)$ $i = 1, \dots, K$, K étant le nombre de classes, nous pouvons effectuer l'**approximation** consistant à prendre comme représentant de la $i^{\text{ème}}$ classe son centre (son milieu) C_i :

$$\bar{x} = \bar{C} = \frac{1}{n} \sum_{i=1}^K n_i C_i = \sum_{i=1}^K f_i C_i,$$

$$\text{où } C_i = \frac{e_i + e_{i+1}}{2}, \quad i = 1, \dots, K.$$

Calcul de la moyenne arithmétique

Remarque

Avantages et inconvénients de la moyenne arithmétique
La moyenne arithmétique se prête facilement au calcul algébrique, mais elle est sensible aux valeurs extrêmes de la série.

Exemple

Si on considère la série de nombres : 1, 5, 7, 4, 3, la moyenne est $\bar{x} = 4$.

Si maintenant, on remplace 3 par 13, la moyenne devient alors $\bar{x} = 6$.

Les modes


Objectif : Nous voulons déterminer les points en lesquels la courbe des fréquences présente un maximum relatif, au sens large.

Série à **valeurs isolées** $(x_j; n_j); j = 1, \dots, J$

Définition

On appelle **mode** de la série, tout élément de la suite **ordonnée** des x_j , dont la fréquence est non-inférieure aux fréquences des deux éléments voisins.

Cas de série bimodale



Cette série admet deux modes : $\text{mode1} = x_3$ et $\text{mode2} = x_6$.

Les modes

Série à valeurs classées $([e_i; e_{i+1}[; n_i)_{i=1,\dots,K}$

Définition

On appelle classe modale toute classe dont la hauteur est non-inférieure aux hauteurs des classes voisines. On prend pour mode le centre (ou milieu) de la classe modale considérée.

Remarques

- Une série statistique peut avoir un ou plusieurs modes.
- Une série à un mode est une série "unimodale".
- Une série à deux modes est une série "bimodale".
- Une série à trois modes est une série "trimodale".
- Une série à plusieurs modes est une série "multimodale".


Remarques : Avantages et inconvénients des modes

- Dans le cas d'une série à valeurs classées, un mode varie suivant le choix des classes.
- Un mode a une signification concrète et sa détermination est simple.
- Le mode n'est pas toujours bien défini dans le cas d'une variable continue.

Exemple

On considère la série suivante qui représente les notes d'un ensemble d'étudiants en un certain module.

3.25 2.5 4.5 4.75 5 5.5 5.75 6.25 10.5 10.75 11.75 12.25 12
15.5 15 16 17.25 18.25 18



Remarques

- La classe modale est celle pour laquelle l'histogramme passe par un maximum.
- La surface totale d'un histogramme des effectifs est égale à n .
- La surface totale d'un histogramme des fréquences est égale à 1.

Objectif : Nous voulons déterminer un nombre tel que 50% des éléments de la série soient inférieurs à ce nombre et 50% lui soient supérieurs.

Définition

La médiane, notée M ou $x_{1/2}$, est la valeur centrale de la série statistique qui partage la série en deux groupes de même effectif.

a) Si la série est à **valeurs isolées**, nous rangeons les éléments de la série par ordre croissant, sans regrouper les éléments égaux.

Nous obtenons :

$$x_{(1)} \leq x_{(2)} \leq x_{(3)} \leq \dots \leq x_{(n)}.$$

Si $n = 2p + 1$ (impair), la médiane $M = x_{1/2} = x_{(p+1)}$.

Si $n = 2p$ (pair), la médiane $M = x_{1/2} = \frac{x_{(p)} + x_{(p+1)}}{2}$.

Avant de parler du cas continu, nous allons définir l'effectif cumulé et la fréquence cumulée.

- (i) On appellera **effectif cumulé** correspondant à la $i^{\text{ème}}$ valeur d'une série statistique le nombre :

$$N_i = \sum_{k=1}^i n_k$$

- (ii) On appellera **fréquence cumulée** correspondant à la $i^{\text{ème}}$ valeur d'une série statistique le nombre :

$$F_i = \sum_{k=1}^i f_k = \sum_{k=1}^i \frac{n_k}{n}$$

b) Si la série est à **valeurs classées**, nous pouvons déterminer une **valeur approchée** de la **médiane** de la manière suivante :

Nous cherchons à quel intervalle $[N_i, N_{i+1}[$ d'effectifs cumulés (resp. $[F_i, F_{i+1}[$ de fréquences cumulées) appartient $n/2$ (resp. $1/2$).

Nous regardons alors la classe $[e_i, e_{i+1}[$ correspondante puis nous déterminons une valeur approchée de la médiane par interpolation linéaire à l'intérieur de cette classe.

$$M = x_{1/2} \simeq e_i + (e_{i+1} - e_i) \frac{n/2 - N_i}{N_{i+1} - N_i} = e_i + (e_{i+1} - e_i) \frac{n/2 - N_i}{n_{i+1}},$$

respectivement

$$M = x_{1/2} \simeq e_i + (e_{i+1} - e_i) \frac{1/2 - F_i}{F_{i+1} - F_i} \simeq e_i + (e_{i+1} - e_i) \frac{1/2 - F_i}{f_{i+1}}.$$

Remarque

La médiane est moins sensible aux valeurs extrêmes que la moyenne.

Exemple

En reprenant les deux séries de l'exemple ci-dessus, on remarque que la médiane est $M = 7$ dans les deux cas alors que la moyenne était très affectée par la valeur extrême.

Les quartiles :

Objectif : Nous voulons déterminer trois nombres Q_1 , Q_2 et Q_3 tels que :

- 25% des éléments de la série soient **inférieurs** à Q_1
- 25% des éléments de la série soient **entre** Q_1 et Q_2
- 25% des éléments de la série soient **entre** Q_2 et Q_3
- 25% des éléments de la série soient **supérieurs** à Q_3 .

Remarques

- Q_2 n'est autre que la médiane.
- La détermination des quartiles est semblable à celle de la médiane.

Le diagramme en boîte ou box-plot ou boîte à moustaches :

C'est un diagramme qui permet de représenter les quartiles, les valeurs extrêmes et les valeurs aberrantes éventuelles (ou erreurs de mesure). Il se présente comme un rectangle de largeur $Q_3 - Q_1$, prolongé par des "moustaches" de part et d'autre de longueur au plus égale à $1.5(Q_3 - Q_1)$

Remarques

- L'écart interquartile : $IQ = Q_3 - Q_1$.
- Les valeurs atypiques sont appelées aussi les valeurs aberrantes.
- La frontière basse Fb est définie par :
$$Fb = Q_1 - 1.5 \times (Q_3 - Q_1) = Q_1 - 1.5(IQ).$$
- L'extrémité gauche de la moustache est définie par :
$$b^- = \text{Inf} \{x_i / x_i \geq Fb\}.$$
- La frontière haute Fh est définie par :
$$Fh = Q_3 + 1.5 \times (Q_3 - Q_1) = Q_3 + 1.5(IQ).$$
- L'extrémité droite de la moustache est définie par :
$$b^+ = \text{Sup} \{x_i / x_i \leq Fh\}.$$




Figure 3 – Le diagramme en boîte.

Paramètres de dispersion

L'étendue :

Définition :

Pour une série à valeurs isolées, **ordonnée**, l'étendue E est la différence entre la plus grande et la plus petite des valeurs de la série :

$$E = x_{(n)} - x_{(1)}.$$

L'écart interquartile :

Définition

L'écart interquartile n'est rien d'autre que $IQ = Q_3 - Q_1$, la différence entre le 3^{ème} et le 1^{er} quartile.

La variance et l'écart-type :

Ils mesurent la dispersion autour de la moyenne.

Définition

La variance d'une série est donnée par la formule suivante :

$$\begin{aligned}s^2 = \text{Variance} &= \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n} \sum_{j=1}^J n_j (x_j - \bar{x})^2 \\ &= \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2 = \frac{1}{n} \sum_{j=1}^J n_j x_j^2 - \bar{x}^2,\end{aligned}$$

$$s = \text{Ecart-type} = \sqrt{\text{Variance}}.$$

Remarque

Dans le cas d'une variable classée, la variance s'écrit :

$$s^2 = \text{Variance} = \frac{1}{n} \sum_{j=1}^K (C_j - \bar{x})^2 = \frac{1}{n} \sum_{j=1}^K n_j C_j^2 - \bar{x}^2$$

Paramètres de forme

Avant de parler des paramètres de forme, nous introduirons la notion de "moments".

Définition :

Soit r un entier naturel.

- (i) On appelle **moment d'ordre r** , de la série $x_1, \dots, x_n$, la quantité :

$$m_r = \frac{1}{n} \sum_{i=1}^n x_i^r = \frac{1}{n} \sum_{j=1}^J n_j x_j^r.$$

- (ii) On appelle **moment centré d'ordre r** , de la série $x_1, \dots, x_n$, la quantité :

$$\mu_r = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^r = \frac{1}{n} \sum_{j=1}^J n_j (x_j - \bar{x})^r$$

Coefficients d'asymétrie :

Dans la pratique, il n'existe pratiquement pas de série symétrique, mais une série peut se rapprocher plus ou moins d'une série symétrique. Nous donnons deux coefficients mesurant cette asymétrie.

- **Coefficient d'asymétrie de Yule** : est basé sur la comparaison de la médiane M et des deux quartiles Q_1 et Q_3 .

$$A_Y = \frac{(Q_3 - M) - (M - Q_1)}{Q_3 - Q_1} = \frac{(Q_3 + Q_1) - 2M}{Q_3 - Q_1}.$$

- **Coefficient d'asymétrie de Fisher** : est basé sur μ_3 , le moment centré d'ordre 3 et S , l'écart-type.

$$g_1 = \frac{\mu_3}{S^3}.$$


Coefficients d'asymétrie :

Si les coefficients d'asymétrie sont :


- Positifs, alors la série est allongée vers la droite.
- Nuls, alors la série est symétrique.
- Négatifs, alors la série est allongée vers la gauche.

Coefficients d'asymétrie :

$$A_Y > 0 \ (g_1 > 0)$$



$$A_Y < 0 \ (g_1 < 0)$$



Coefficient d'aplatissement β_2 de Pearson :

Il est basé sur le moment centré d'ordre 4 et normalisé par l'écart-type :

$$\beta_2 = \frac{\mu_4}{s^4}$$




Figure 4 – Coefficient d'aplatissement β_2 de Pearson.

Coefficient d'aplatissement β_2 de Pearson :

- Dans le cas d'une loi normale $\beta_2 = 3$.
- Si $\beta_2 < 3$ la courbe est dite platicurtique, plus plate que la loi normale.
- Si $\beta_2 > 3$ la courbe est dite leptocurtique, plus pointue que la loi normale.
- La comparaison des courbes n'a de sens que si les séries sont de même moyenne et de même écart-type.

Bon courage et bonne
compréhension