

Statistique Descriptive Bivariée "Contingence"

Pr. L. A. Allamy

Université Cadi Ayyad
Faculté des Sciences Semlalia Marrakech

1^{er} décembre 2024

"Contingence"

INTRODUCTION

Objectif

- L'objectif de cette partie est d'étudier, sur une même population de N individus, deux caractères différents X et Y et de chercher s'il existe un lien entre ces deux variables.
- Chacune des deux variables peut être, soit quantitative soit qualitative.

Représentations des données

On donnera les représentations des données :

- en utilisant les effectifs,
- en utilisant les proportions ou fréquences.

Représentation des données avec les effectifs

Notations

- On notera x_i ($i = 1, \dots, k$) les k modalités ou valeurs de la variable X .
- On notera y_j ($j = 1, \dots, l$) les l modalités ou valeurs de la variable Y .

Définition

On appellera distribution jointe des effectifs de X et Y , l'ensemble des couples (x_i, y_j) , $i = 1, \dots, k$ et $j = 1, \dots, l$ munis de leurs effectifs n_{ij} , $i = 1, \dots, k$ et $j = 1, \dots, l$ correspondants :

$$((x_i, y_j), i = 1, \dots, k \text{ et } j = 1, \dots, l)$$

Tableau de contingence des effectifs

Pour représenter la distribution jointe du couple (X, Y) , on utilise un tableau à double entrée appelé :
“tableau de contingence”.

$X \backslash Y$	y_1		y_j		y_l	Total
x_1	n_{11}		n_{1j}		n_{1l}	$n_{1.}$
.						
.						
x_i	n_{i1}		n_{ij}		n_{il}	$n_{i.}$
.						
.						
x_k	n_{k1}		n_{kj}		n_{kl}	$n_{k.}$
Total	$n_{.1}$		$n_{.j}$		$n_{.l}$	$n_{..} = N$

Exemple

Exemple

On s'intéresse à la relation qui pourrait exister entre le sexe (variable X) et la couleur des yeux (variable Y), de 200 personnes.

X	Y	Marrons	Bleus	Verts	Total
Homme		$n_{11} = 10$	$n_{12} = 50$	$n_{13} = 20$	$n_{1.} = 80$
Femme		$n_{21} = 20$	$n_{22} = 60$	$n_{23} = 40$	$n_{2.} = 120$
Total		$n_{.1} = 30$	$n_{.2} = 110$	$n_{.3} = 60$	$n_{..} = 200$

Distributions marginales

On ajoute au tableau de contingence les totaux en lignes et en colonnes.

- En marge de droite : totaux des effectifs se trouvant sur une même ligne.
- En marge en bas : totaux des effectifs se trouvant sur une même colonne.

Distribution marginale de X

La distribution de X pour l'indice i est l'effectif $n_{i.}$, égal au nombre d'observations de la modalité x_i de X , quelle que soit la modalité de Y .

$$\begin{aligned}n_{i.} &= \sum_{j=1}^I n_{ij} &&= n_{i1} + n_{i2} + \dots + n_{iI} \\&= \text{total de la ligne } i\end{aligned}$$

Définition

Les couples $(x_i, n_{i.})$, $i = 1, \dots, k$ définissent la **distribution marginale de la variable X** .

Remarque

Remarque

$$\sum_{i=1}^k n_{i.} = N = n_{1.} + n_{2.} + \dots + n_{k.}$$

Exemple

Exemple

On reprend les données du tableau croisé du sexe et de la couleur des yeux.

X	Homme	Femme	Total
Effectif	80	120	200

Distribution marginale de Y

D'une façon analogue, on définit la distribution marginale de Y .

$$\begin{aligned}n_{.j} &= \sum_{i=1}^k n_{ij} &&= n_{1j} + n_{2j} + \dots + n_{kj} \\&= \text{total de la colonne } j\end{aligned}$$

Définition

Les couples $(y_j, n_{.j})$, $j = 1, \dots, l$, définissent la **distribution marginale de la variable Y** .

Remarque

Remarque

$$\sum_{j=1}^I n_j = N = n_{.1} + n_{.2} + \cdots + n_{.\ell}$$

Exemple

Exemple

En utilisant, toujours les données de l'exemple croisant les deux caractères, sexe et couleur des yeux, on obtient :

Y	Marrons	Bleus	Verts	Total
Effectif	30	110	60	200

Représentations des données avec les proportions (ou fréquences)

Tableau de contingence des proportions (ou fréquences)

Le tableau est analogue au tableau de contingence précédent, sauf que les effectifs sont remplacés par les proportions (ou les fréquences).

Exemple

Exemple (sexe, couleur des yeux)

$X \backslash Y$	Marrons	Bleus	Verts	Total
Homme	$p_{11}(0, 05)$	$p_{12}(0, 25)$	$p_{13}(0, 10)$	$p_{1.}(0, 40)$
Femme	$p_{21}(0, 10)$	$p_{22}(0, 30)$	$p_{23}(0, 20)$	$p_{2.}(0, 60)$
Total	$p_{.1}(0, 15)$	$p_{.2}(0, 55)$	$p_{.3}(0, 30)$	$p_{..} = 1$

Tableau des $((x_i, y_j); p_{ij})$ (ou f_{ij}), $i = 1, \dots, k$ et $j = 1, \dots, l$

Remarque

Remarque

La proportion du couple (x_i, y_j) est :

$$p_{ij} = f_{ij} = \frac{n_{ij}}{N} \quad N = 200$$

Proportions marginales

Ces proportions marginales s'obtiennent facilement :

$n_{i.}$ est remplacé par $p_{i.} = \frac{n_{i.}}{N}$

$n_{.j}$ est remplacé par $p_{.j} = \frac{n_{.j}}{N}$

Proportions marginales : Exemples

Pour X :

X	Homme	Femme	Total
Effectif	80	120	200
Proportion	$(p_{1.} = \frac{80}{200}) = 0,40$	$(p_{2.} = \frac{120}{200}) = 0,60$	1

Tableau des $(x_i, p_{i.})$; $i = 1, \dots, k$

Pour Y :

Y	Marrons	Bleus	Verts	Total
Effectif	30	110	60	200
Proportion	$p_{.1} (\frac{30}{200}) = 0,15$	$p_{.2} = 0,55$	$p_{.3} = 0,30$	1

Tableau des $(y_j, p_{.j})$; $j = 1, \dots, l$

Indépendance entre deux variables

Etant données deux variables statistiques X et Y dont la distribution jointe est donnée par un tableau de contingence, on se pose la question suivante :

“Est-ce que ces deux variables sont indépendantes ?”

On considère la quantité :

$$q^2 = \sum_{i=1}^k \sum_{j=1}^l \frac{[(n_{ij}) - (n_{i.} \times n_{.j})/n]^2}{(n_{i.} \times n_{.j})/n}$$

Les $(n_{ij}/n)_{i=1,\dots,k; j=1,\dots,l}$ représentent les **fréquences observées**, alors que les $((n_{i.}/n) \times (n_{.j}/n))_{i=1,\dots,k; j=1,\dots,l}$ représentent les **fréquences théoriques** sous l'hypothèse d'indépendance des deux variables X et Y .

Mesure V de Cramér

Question

Comment pouvoir donner une bonne interprétation, en termes d'indépendance, à q^2 alors qu'il peut prendre des valeurs de 0 à l'infini ?

Posons : $\phi^2 = \frac{q^2}{n}$.

On peut montrer que :

$$\phi^2 \leq \min(k-1, l-1).$$

On définit ensuite la mesure V , dite de Cramér :

$$V = \sqrt{\frac{\phi^2}{\min(k-1, l-1)}} \in [0; 1]$$

- Plus V est proche de zéro ($V \simeq 0$), moins les variables sont **dépendantes**.
- Il vaudra donc 0 lorsque X et Y sont **indépendantes**.
- Au contraire, il vaudra 1 lorsqu'elles sont **complètement dépendantes**.

La liaison entre les deux variables est d'autant plus grande que V est plus proche de 1.

Pour aider l'interprétation des valeurs de ce coefficient, on dresse le tableau suivant :

Valeur du coefficient de Cramér	Intensité du lien entre variables
$V < 0.10$	nulle ou très faible
$0.10 \leq V < 0.20$	faible
$0.20 \leq V < 0.30$	moyenne
$V \geq 0.30$	forte

Fin de la partie "Contingence"
BON COURAGE