

Statistique Descriptive Bivariée "Régression"

Pr. L. A. Allamy

Université Cadi Ayyad
Faculté des Sciences Semlalia Marrakech

25 novembre 2024

"Régression"

Remarque

Dans cette partie, on ne considèrera que les variables statistiques quantitatives.

Exemple

$(X, Y) = (\text{taille (en cm)}, \text{poids (en kg)})$

X	155	163	170	178	185
Y	47	61	54	70	73

Coefficient de corrélation

Considérons deux variables statistiques quantitatives X et Y . Souvent, on se pose la question d'existence d'un lien, d'une relation entre X et Y et éventuellement l'exprimer mathématiquement.

Nuage de points

Soient $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$, n observations du couple (X, Y) (un n -échantillon de (X, Y)).

Ces couples peuvent être représentés dans un plan orthogonal (x_i en abscisse et y_i en ordonnée) et donnent alors naissance à ce qu'on appelle "un nuage de points".

Définition

On mesure le lien de dépendance linéaire entre deux variables quantitatives X et Y par le coefficient de corrélation, noté r_{XY} , défini par :

$$r_{XY} = \frac{s_{XY}}{s_X s_Y}$$

où $s_{XY} = \frac{1}{n} \sum_i x_i y_i - \bar{x} \bar{y}$ et $s_X^2 = \frac{1}{n} \sum_i x_i^2 - \bar{x}^2$.

On rappelle que $\bar{x} = \frac{1}{n} \sum_i x_i$, $\bar{y} = \frac{1}{n} \sum_i y_i$


Remarque

- $r_{XY} \in [-1, 1]$
- $|r_{XY}| = 1 \Leftrightarrow$ dépendance linéaire parfaite entre X et Y .

Exemple-suite

- La taille moyenne est : $\bar{x} = 170,2$ cm.
- Le poids moyen est : $\bar{y} = 61$ kg.
- $s_{XY} = \left(\frac{52373}{5}\right) - \bar{x}\bar{y} = 92,4$.
- $s_X^2 = \frac{1}{5}(145403) - (\bar{x})^2 = 112,56 \rightarrow s_X = 10,6094$.
- $s_Y^2 = \frac{1}{5}(19075) - (\bar{y})^2 = 94 \rightarrow s_Y = 9,695359$.
- $r_{XY} = \frac{92.4}{\sqrt{94 \times 112.56}} = 0.89829 \Rightarrow$ il y a une forte liaison linéaire entre la taille et le poids.

Représentation d'un nuage de points



Droite de régression

En régression linéaire, on cherche à déterminer une droite qui ajuste le mieux possible le nuage.

On utilise la méthode des moindres carrés.

Cette méthode consiste à trouver la droite (D) : $y = ax + b$ qui approche le mieux le nuage, au sens des moindres carrés. Ceci revient à minimiser la somme des carrés des écarts entre :

- y_i (ordonnée de x_i dans le nuage) et
- $ax_i + b$ (ordonnée de x_i sur la droite).

Droite de régression

On cherche alors à minimiser : $\sum_{i=1}^n (y_i - (ax_i + b))^2$

On obtient alors ce minimum pour :

$$\hat{a} = \frac{s_{XY}}{s_X^2} \text{ et } \hat{b} = \bar{y} - \hat{a}\bar{x}$$

$$\text{où } \bar{x} = \frac{1}{n} \sum_i x_i, \bar{y} = \frac{1}{n} \sum_i y_i, s_{XY} = \frac{1}{n} \sum_i x_i y_i - \bar{x}\bar{y} \text{ et}$$

$$s_X^2 = \frac{1}{n} \sum_i x_i^2 - \bar{x}^2$$

Equation de la droite de régression

L'équation de la droite de régression est donnée par :

$$(D) : y = \hat{a}x + \hat{b}$$

$$\text{où } \hat{a} = \frac{s_{XY}}{s_X^2} \text{ et } \hat{b} = \bar{y} - \hat{a}\bar{x}$$

Remarque

- La droite de régression passe par le point $(\bar{x}, \bar{y})$.
- Elle donne un modèle de prédiction. On peut prédire des valeurs qui ne figurent pas dans le tableau, à partir de l'équation de la droite.

Relation entre les coefficients

On a la relation suivante, entre $\hat{a}$ et r_{XY} :

$$\hat{a} = r_{XY} \times \frac{s_Y}{s_X}$$

en effet : $\hat{a} = \frac{s_{XY}}{s_X^2} = \frac{s_{XY}}{s_X \times s_Y} \times \frac{s_Y}{s_X} = r_{XY} \times \frac{s_Y}{s_X}$

Exemple-suite

- La taille moyenne est : $\bar{x} = 170,2$ cm.
- Le poids moyen est : $\bar{y} = 61$ kg.
- $s_{XY} = \left(\frac{52373}{5}\right) - \bar{x}\bar{y} = 92,4$.
- $s_X^2 = \frac{1}{5}(145403) - (\bar{x})^2 = 112,56 \rightarrow s_X = 10,6094$.
- $s_Y^2 = \frac{1}{5}(19075) - (\bar{y})^2 = 94 \rightarrow s_Y = 9,695359$.
- $\hat{a} = \frac{s_{XY}}{s_X^2} \simeq 0,82089$.
- $\hat{b} = \bar{y} - \hat{a}\bar{x} \simeq -78,7$.

Exemple-suite

L'équation de la droite de régression est : $y = 0,821x - 78,7$

→ On voudrait prédire le poids d'une personne ayant une taille de 1,80 m :

$$y = 0,821 \times 180 - 78,7 = 69,08$$

Le poids recherché est presque égal à 69 kg.

Représentation du nuage de points





Figure 2 – Nuage de points taille-poids

Tracé du nuage de points et de la droite de régression



Résidus ou erreurs de prédiction

Les **résidus de la régression linéaire** sont définis par :

$$e_i = y_i - (\hat{a}x_i + \hat{b}) = y_i - y_i^*; \quad i = 1, \dots, n$$

- Le résidu e_i est l'erreur que l'on commet en utilisant la droite de régression linéaire pour prédire y_i à partir de x_i .
- Les résidus sont les différences entre les valeurs observées y_i et les valeurs ajustées y_i^* ; $i = 1, \dots, n$.

- Moyenne résiduelle : $\bar{e} = \frac{1}{n} \sum_{i=1}^n e_i = \frac{1}{n} \sum_{i=1}^n (y_i - (\hat{a}x_i + \hat{b}))$

- Variance résiduelle : $s_e^2 = \frac{1}{n} \sum_{i=1}^n e_i^2 - (\bar{e})^2$

Remarques

- On a toujours $\sum_{i=1}^n e_i = 0$.
- La variance résiduelle s'écrit alors :
$$s_e^2 = \frac{1}{n} \sum_{i=1}^n e_i^2 = s_Y^2 [1 - r_{XY}^2].$$
- La variance résiduelle est la variance non expliquée par la droite de régression de Y en X .

Fin de la partie 2
"Statistique descriptive
bivariée"
BON COURAGE